

- No free lunch theorem

Žádný algoritmus není vhodný na všechno (není univerzální), je třeba vybírat dle problému.

- Single objective and multi-objective optimization: differences, approaches

Single - Optimalizace jedné funkce

Multi - Optimalizace více funkcí - složitější pro implementaci - využití paretových linií pro výsledky

- Každá z funkcí se může buď maximalizovat, nebo minimalizovat

- Infeasible solution - neexistuje řešení, které by vyhovovalo všem požadavkům

- Reprezentace n-dimenzionálním grafem

Approach - Multi-objektová optimalizace se dá reprezentovat i single přístupem, stačí složit všechny funkce do jedné (sečíst), bohužel tím nemáme neměnný vhodný výsledek (je třeba vhodně vyvážit všechny funkce vůči sobě)

- Lepší varianta je kontrolovat hodnoty všech funkcí a pak v nich hledat pareto linii

- Types of test functions

Statické - neměnné v čase, často známe přesné hodnoty extrémů a toužíme je vyhledat našim algoritmem (Rastrigin, Levy, Griewank, Schwefel, Ackley, Sphere)

Dynamické - mění pozici extrému v čase

- Artificial - uměle vytvořené "arény" (matice místo předpisu)

- Real - nedeterministický předpis

Deceptive - mají velké klamné lokální extrémy pro zmatení algoritmu (ověření spolehlivosti?)

- Pareto set

Slouží pro interpretaci optimalizace více funkcí

Může být n-dimenzionální, podle počtu n-funcí

Kombinace výsledků taková, že optimalizace jedné funkce, nezhorší funkci druhou (zlepšení jedné funkce je možné jen na úkor jiné)

Infeasible X feasible

Lze vytvářet více paretových linií

- Traveling salesman problem: suitable algorithms

Ant Colony, Genetický algoritmus

- Local search algorithms: hill climbing, tabu search, simulated annealing

- Evolution strategy: principle, variants

- založeno na evoluci jedinců
- využívají mutace, křížení, generace
- nejlepší řešení (jedinec) se musí uchovávat, není zajištěno přežití generace

$(1 + 1)$ - ES - jeden rodič, potomek má přidanou odchylku k hodnotám

$(1 + \lambda)$ - ES - více mutací z jednoho rodiče

$(1, \lambda)$ - ES - nejlepší mutant je nový rodič, původní se zahodí

(μ, λ) ES- μ rodičů, λ potomků, rodiče se zahodí

$(\mu + \lambda)$ ES- μ rodičů, λ potomků, rodiče se nechají

$(\mu/p + \lambda)$ ES- kombinace z několika předpotomků

Adaptive - ES

- The normal distribution in evolutionary algorithms

- pro mutaci reálných souřadnic lze využít norm. Rozdělení
- pro strategie s jedním rodičem

$N(E, G)$

E - součet hodnot??? (sovětí hodnota???)

G - Variace

- Evolutionary algorithms - typical phases, examples of algorithms

Fáze - Generace populace \rightarrow mutace \leftrightarrow cross-over , vybrání nové populace, uložení nej jedince

Příklad - Genetic alg. (Diferencial evolution)

- Částečně SOMA

- Swarm intelligence - typical phases, examples of algorithms

-Particle swarm, SOMA (Self-Organizing Migrating Algorithm), ant-colony, firefly
Pohyb a migrace velkých populací, popis pohybu jedinců jinými způsoby

- Genetic algorithm - types of crossover

- Differential evolution - mutation vector, trial vector, target vector, mutation strategies, crossover, natural selection, control parameters

- Particle swarm optimization - pBest, gBest, velocity, inertia weight, equation of movement, control parameters

pBest - nejlepší řešení pro jednu částici

gBest - nejlepší řešení ze všech částic

- Self-organizing migrating algorithm - leader, strategies, equation of movement, control parameters

- Ant colony optimization - probabilities of movement, recalculation of pheromones

https://drive.google.com/file/d/1_iMQ3siL5aJ6pdnVbty4lx-6erri24GO/view

Princip:

Každý mravenec při svém cestování produkuje feromony. Cestování je zpočátku náhodné, ale čím častěji mravenci nějakou cestu využívají, tím silnější je feromonová stopa a mravenci začínají tuto cestu upřednostňovat. (Čím kratší cesta, tím silnější feromonová stopa.) Postupem času se feromonová stopa vypařuje (vaporization), díky toho cesty, které nejsou nejkratší, nejsou pro mravence tak atraktivní.

Vstupní parametry:

α ... stupeň důležitosti feromonů (jakou mravenci přiřazují feromonům důležitost)

β ... stupeň důležitosti vzdálenosti (mezi městy; jak důležitá je pro mravence vzdálenost)
 $\rho \in [0,1]$... evaporation rate (jak rychle má docházet k vypařování)
 $u \in M_k$... ?
 Q ... nějaká nesmyslná konstanta... většinou to je 1

Vzorec:

Šance, že mravenec K v místě R vybere cestu k místu S se vypočítá:

(feromony)
pheromone

$$p_k(r, s) = \begin{cases} \frac{\tau(r, s)^\alpha \eta(r, s)^\beta}{\sum_{u \in M_k} \tau(r, u)^\alpha \eta(r, u)^\beta}, & \text{for } s \in M_k \\ 0, & \text{otherwise} \end{cases}$$

$\frac{1}{d(r, s)}$
(vzdálenost)

■ ■ ■

- Firefly algorithm - the movement of fireflies, equation of movement, control parameters

$$X_i + (\beta * (1/(\omega + r)) * (X_j - X_i)) + \alpha * (\text{random} - 0.5)$$

- Teaching-learning based algorithm - teaching phase, learning phase, teacher, mean, learner, control parameters

- Diversity of population - positive and negative influences. How to preserve the diversity of the population. Premature convergence

- Elitism and its influence on the algorithm convergence

- Complexity of algorithms

- Number of evaluations of the objective function

- NSGA II: Principle, fast non-dominated sorting


- explorácia vs exploitácia

Have no fcking idea, vraj to pár krát spomenula na prednáške.

BIOLOGICKY INSPIROVANE ALGORITMY

① NO FREE LUNCH THEOREM

- Nelze dobře hodnotit dva algoritmy a říci, že jeden je lepší, jak druhý.
- Každý alg. je vhodný na určitý problém



- Výsledkem je, že při hodnocení algoritmu je nutné orientovat na přesný problém.


② SINGLE OBJECTIVE & MULTI-OBJECTIVE OPTIMIZATION: DIFFERENCES, APPROACHES

SINGLE - optimalizace jedné funkce

MULTI - optimalizace více funkcí, v něco obviťjší pro implementaci, využít Paretových limit pro výsledky (oproti jednomu bodu)



- každá z funkcí se může buď maximalizovat nebo minimalizovat
- INFEASIBLE solution - nemožný požadavek
- reprezentace n-dimenzionálním grafem (každá osa pro jednu funkci)



APPROACH - multi-obj. opt. se dá reprezentovat i SINGLE přístupem, stačí složit všechny funkce do jedné (seřadit), bohužel tím nemáme rovněž vhodný výsledek (je třeba vhodně využít všechny funkce vůči sobě).

- Lepší varianta je kontrolovat hodnoty všech funkcí a pak ověřit hledat paretovými liniemi.

③ TYPES OF TEST FUNCTIONS

STATICKÉ: minimálna rešenie, často máme prítomnosť lokálnych extrémov a zložitšie je vybrať minimálny algoritmus

- 1st De Jong




- 2nd De Jong, saddle



- 3rd De Jong



- Rastrigin




DYNAMICKE: mení pozíciu extrémov časom

- ARTIFICIAL - umelo vytvárané úlohy (matematické predpisy)

- REAL - prírodné úlohy (prírodné predpisy)

DECEPTIVE: má veľa matematických lokálnych extrémov a je.



④ PARETO SET



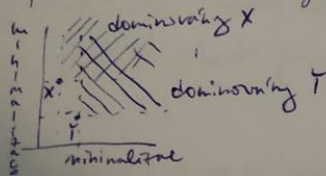
- pro interpretaci optimalizace více funkcí

- musí být n -dimenzionální, podle počtu (n) fci

- kombinace výsledků taková, že snížení jedné fce neruší jiné funkce

INFEASIBLE x FEASIBLE

- řešení v. poměrně blízké dominantní řešení ostatní



- | | |
|----------|----------|
| 1. | 2. |
| max, max | min, max |
| min, max | max, min |
| min, min | max, min |
| max, min | min, max |

- lze vyjádřit více poměrných linií: 1, 2, 3, 4...



PRINCIPLE, VARIANTS

- zalesňba na evropské jedinci
- vyuzívají mutace, křížení, generace
- nejlepší řešení je nyní uchovávat, než zjištěno je přínosné zhybní
- (1+1)-ES - jeden rodič, protože má přímou odchylnu z hodnotám (jeden mutant)
- (1+λ)-ES - více mutantů z jednoho rodiče
- (1,λ)-ES - nejlepší mutant z genových rodičů, přirození z hybridů
- (μ, λ)-ES - rodičů, λ potomků, ~~z~~ rodičů z hybridů
- (μ+λ)-ES - 1 - nejlepší
- (μ/ρ+λ)-ES - kombinace z hybridů předpotomků
- Adaptive-ES

8. NORMAL DISTRIBUTION IN EVOLUTIONARY Algorithms

- pro mutaci reálných souvisejících bezvýhradně norm. rozdílů
- pro strategii spjatým roztokem

$$N(E, G)$$

spread variance

⑨ EVOLUTIONARY ALG. PHASES, EXAMPLES

PHASES - ^{genetic} ~~population~~ ^{h.} ~~mutate~~, cross-over, vibration, ~~none~~ ^{genetic} ~~population~~, ~~population~~ nej. jedince

EXAMPLES - Genetic alg. (Differential evolution)

CASTECNE SOMA, ~~swarm~~ PARTICLE SWARM

⑩ SWARM INTELLIGENCE - PHASES, EXAMPLES

- Particle swarm, SOMA (self-organizing migrating alg), ant-colony opt, firefly opt, teaching-learning based alg.
- Polybl and grace veltz'ah populaci, POPIS polybl-jedinci jiny'ni zpusoby

⑤ TRAVELING SALESMAN PROBLEM SUITABLE ALGORITHMS

- TSP, problem hledání nejmenšího Hamiltonského cyklu, NP TIME těžký problém.
- s dlouhých rozměrů řešitelný brute force.
- uhl projekt rozdělování genů a vrátit se do poč. ~~rozdělování~~ rozdělování v co nejkratší vzdálenosti.

ALGORITHM - evoluční (genetický) algoritmus
- ant-colony opt.

⑥ LOCAL SEARCH ALGORITHMS: HILL CLIMBING, TABU SEARCH, SIMULATED ANNEALING

- Algoritmy ~~pro hledání lokálního optima~~ pro hledání lokálního optima ~~pro hledání lokálního optima~~

Hill climbing - začíná náhodným bodem, podle generuje bod normálním rozdělením v range z parametru.
(křivka)
Pokud je nový bod lepší, jak předchozí, bere ho jako nový státní a stále takto postupuje.



- Velká pravděpodobnost lok. extrému
- Uhlazením může být např. počet podobných jedinců nebo počet generací.

Tabu Search - podobné jako hill climbing, ale má paměť předchozích uvolněných řešení, kterých jsou "tabu" a nemůže se k nim vrátit (více exploze), a má

simulated annealing - podobné hill cl., ale dokáže se dostat z lokálních extrémů

- Zmrazíme, dokud nedosáhneme požadovanou teplotu (postupně ji snižujeme)
- generujeme normální rozdělení, pokud nový je lepší, vyhodíme ho a stále nezmrazíme.
- pokud není lepší, dále musíme přigřívět podle aktu. teploty a rozdílů ve funkcích hodnotách.

④ EVOLUTION STRATEGY

PRINCIPLE, VARIANTS

- založení na evoluční dějinách
- využívají mutace, křížení, generace
- nejlepší řešení se musí uchovávat, není zajištěno nejlepší řešení
- $(1+1)$ -ES - jeden rodič, potomek má přidatnou odchylku z hodnotám (ještě mutace)
- $(1+\lambda)$ -ES - více mutantů z jednoho rodiče
- $(1,\lambda)$ -ES - nejlepší mutant z nového rodiče, původní se zahodí
- (μ,λ) -ES - μ rodičů, λ potomků, μ rodičů se zahodí
- $(\mu+\lambda)$ -ES - $\mu + \lambda$ - nehygi
- $(\mu/\lambda+\lambda)$ -ES - kombinace z několika předpotomků
- Adaptive-ES

⑧ NORMAL DISTRIBUTION IN EVOLUTIONARY ALGORITHMS

- pro mutaci reálných souřadnic lze využít norm. rozdělení
- pro strategii s jedním rodičem

$$N(\mu, \sigma)$$

průměr rozptyl
hodnota

⑨ EVOLUTIONARY ALG. PHASES, EXAMPLES

PHASES - ^{generace rodičů} ~~populace~~ ^{mutace} ~~mutace~~, cross-over, výběr nové ~~generace~~ populace, pak automaticky nejlepší

EXAMPLES - Genetic alg. (Differential evolution)

ČÁSTEČNĚ SOMA, SWARM PARTICLE SWARM

⑩ SWARM INTELLIGENCE - PHASES, EXAMPLES

- Particle swarm, SOMA (self-organizing migrating alg), ant-colony opt, firefly opt, teaching-learning based alg.
- pohyb a migrace velkých populací, popis pohybů jedinců jímání a přenosy

14 SELF-ORGANIZING MIGRATING ALG.

- náhodná perturbace vektoru, $\neq 0$ a 1 ,

počet generací $\leq PRT \rightarrow 1$
 $\rightarrow 0$

- každá migrace musí mít LEADERA

1. náhodná populace

2. zvolení leadera


3. pohyb každého jedince - vektor k leaderovi = $(\text{leader-position}) * PRT\text{vector}$

- $\text{tmp.} = \text{position} + \text{STEP} \cdot \text{vector}$

- vyzkoušeme všechny strany a

získáme nejlepší variantu,

to pokračujeme do další migrace



pathlength (1, 5) - overskip

step (0, 1; pathlength)

PRT (0, 1)

STRATEGY - All to One - move to leader

- All to All - move to each other

- All to All Adaptive - move positive a autonomously při rovnou do aktuální populace

- All to One Rand - move to random individual

15 ANT COLONY OPTIMIZATION

- pro lokální optimalizace

- DISTANCE matice, FEROMONOVÁ matice, VISIBILITY matice

1. náhodně zvolíme start a body migrace

2. seřadíme podle

pro všechny migrace

$$\frac{PHER \cdot \frac{1}{\alpha} \cdot \frac{1}{\beta}}{\sum \text{pro normalizaci}}$$

oproti dohled

nebo nevidíme místo

3. upravit feromony - evaporace a

cesty jednotlivých migrací $+ \frac{PHI}{dist}$

ALPHA - hodnota feromonu

BETA - hodnota distance


evaporation const - úroveň vypařování

PHI - hodnota pro feromony
 při číselní feromony

11 Genetic algorithm

- based on principles of evolution
- vhodný pro diskrétní optimalizaci (TSP)

- používá ruletu pro výběr rodičů - srovná fitness rodičů a podle jím daných 1, 2, 3... , poté generuje nová čísla a vybere




- CROSSOVER - výměna částí dvou chromozomů.

- ONE POINT

- TWO POINT



- MULTIPPOINT - sance nahrazení náhodou



(Diff. evolution)

- MUTATE - nahradí alternancí jedné části chromozomu

- Počet jedinců v populaci je nastaven.

12 DIFFERENTIAL EVOLUTION

- evoluční algoritmus
- pro reálná čísla

scaling vector

- generuje nové náh. jedince, pro které ho může být 3 jiné, a nich vytvoří $MUTATION VECTOR = x_1 + F(x_2 - x_3)$, a nej a původního jedince vytvoří $TRIAL VECTOR$ pomocí $UNIFORM crossover$.

TARGET VECTOR

Pokud trial je lepší než target, je přijat do nové populace (jinak je přijat Target) \Rightarrow NATURAL SELECTION

strategie Crossover - binární

- probíráme 0 a 1

strategie Mutation - 3 vektorů, 7 vektorů

Natural selection CONTROL PARAMETERS - F... scaling vector 0-1 (0,5)

CR... crossover rate 0-0,2

NP... number of p. 5-100

13 PARTICLE SWARM

- random population

- celou dobu si hledá globalBEST

- každý jedinec si drží svůj personalBEST, pozici a pohyb, který měl na poslední

- migrace - $Polyb = Polyb(předešlý) \cdot váha + C_1 \cdot (pBest - pozice) + C_2 \cdot (gBest - pozice)$

vektor z pozice do bestu

- má tendenci uschovat konvergovat

C_1 ... koeficient k pBest

C_2 ... koeficient k gBest

váha... koeficient rychlosti (inertia weight)